La MasIA

More Than A Hack 2027 · Fase 1: posesión por frame

Informe de estado: qué hemos hecho, por qué, dónde fallamos y qué viene

24 de octubre de 2026 · Rama **banco-v3** del repositorio github.com/ManelCM/FCBCN_HACK_2027 ·
Preparado por Manel con el agente

Para quién es esto. Para ponernos al día los tres. Está escrito para leerse de principio a fin (unos 30-40 minutos), pero cada sección se entiende sola. Los números salen de `docs/experimentos.md` (identificadores E001-E037) y de los ADR de `docs/decisiones/`. Si algo de aquí contradice esos ficheros, mandan ellos.

1. Resumen en una página

La tarea. Para cada uno de los 199.319 frames del Barça-Athletic hay que decir si el balón es del Barça (H), del Athletic (A) o está muerto (D). Se puntúa con **spellF1**, que premia acertar **posesiones enteras** (no frames sueltos). El baseline oficial saca 0,243. No hay leaderboard: solo sabremos la nota al final.

Dónde estamos.

- Tenemos un modelo que en nuestro banco de validación (10 partidos públicos estropeados para parecerse al tracking del reto) saca **0,7185** de spellF1. Hace dos días sacaba 0,6245 en un banco más pequeño, y la referencia del banco actual era 0,6470.
- La gran mejora de esta semana (**+0,072**, E035) viene de las **familias de features pensadas como las mira un entrenador**: balón, jugadores (quién aprieta, quién esprinta, quién se desmarca, el portero), bloques (cómo de juntos y abiertos están, altura de líneas) y estructura (forma con y sin balón, cuántos hay por detrás del balón).
- Estimación orientativa en el reto: el banco suele ser algo más fácil que el reto (~0,04 con el baseline). Con el modelo nuevo, esperamos **del orden de 0,62-0,68**, muy por encima del 0,243 del baseline. Es una estimación con mucha incertidumbre (±0,05 o más).
- `La MasIA.csv` existe, es válido y reproducible bit a bit, pero **todavía sale del modelo anterior** (0,6245 en el banco pequeño). Hay que regenerarlo con el modelo nuevo.

Qué falta (por orden).

1. Ablación por familias (quitar una cada vez) para saber de dónde sale la mejora y descartar que sea un artefacto del simulador. La primera ablación se cortó al reiniciarse la sesión; hay que relanzarla.
2. Entrenar el modelo final con los 10 partidos y regenerar `La MasIA.csv` (dos veces, mismo sha) + prueba de humo con los 5 minutos públicos.
3. Documento técnico definitivo, repositorio público, PR a main aprobada por un compañero, y subir el formulario antes del 17 de noviembre (congelamos el 14).

Qué necesitamos de vosotros. Enviar el email con las preguntas a la organización (Q2/Q4/Q5/Q6); aceptar la invitación de GitHub y revisar la PR; confirmar los tres la inscripción antes del 10 nov; decidir entre los tres si el ADR-0004 recoge que el agente ejecute scripts de solo agregados (sección 11).

2. El reto y la métrica

2.1 La tarea

Un partido: FC Barcelona (local, H) - Athletic Club (visitante, A), LaLiga 2024-25, jornada 2. El vídeo táctico tiene 199.319 frames a 25 fps; se puntúan 158.857 (las dos partes). Por cada frame se entrega una etiqueta:

Etiqueta	Significado
H	Posesión del Barça con el balón vivo
A	Posesión del Athletic con el balón vivo
D	Balón muerto (falta, fuera, gol, descanso de juego...)
X	Sin respuesta; solo la usamos fuera de las partes, donde no cuenta

Entregables: `La MasIA.csv` (199.319 filas), un repositorio **público** que regenere **exactamente** el mismo fichero con un comando, y un documento técnico corto. Fecha límite: 17 de noviembre. Pasan los 20 mejores a la fase 2.

2.2 Por qué spellF1 lo cambia todo

spellF1 no cuenta frames: cuenta **posesiones**. Una posesión es una racha seguida de H o de A; un D en medio la corta. Cada posesión predicha se empareja con una real si se solapan lo suficiente (IoU, intersección entre unión) y se promedia la F1 en umbrales de IoU de 0,3 a 0,7. Consecuencias prácticas:

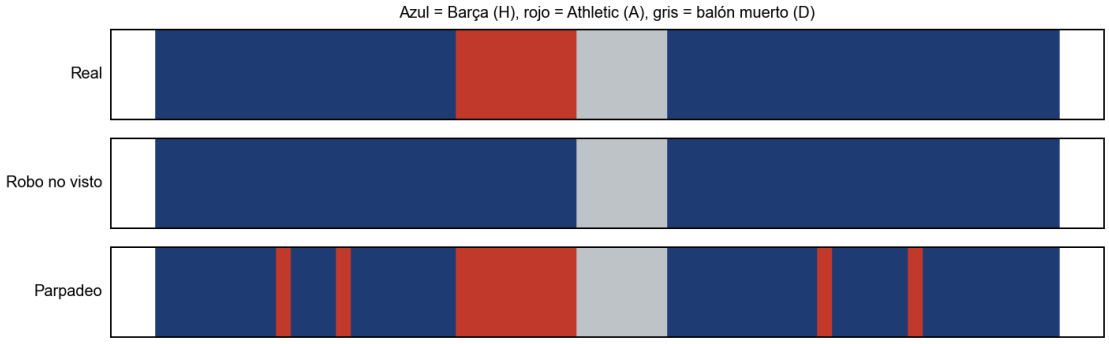


Figura 1. Arriba, la realidad: H, luego A (un robo corto), luego un parón y otra vez H. En medio, un modelo que no ve el robo: une las dos posesiones del Barça y pierde la del Athletic. Abajo, un modelo que 'parpadea': cada parpadeo crea dos posesiones falsas y rompe una buena. Las dos cosas se pagan muy caras, aunque el acierto por frame sea alto.

- **No ver un robo cuesta 2-3 posesiones**: la del rival desaparece y las dos del otro equipo se funden en una que ya no empareja con ninguna.
- **Parpadear es letal**: el baseline oficial sin suavizar tiene macroF1 0,65 pero spellF1 0,05.
- **Llegar 1 segundo tarde a un cambio cuesta ~35 %** de la nota, porque hay muchas posesiones cortas.
- **Detectar bien los D** importa: un parón no detectado funde dos posesiones; un D falso parte una.
- La organización avisa de que diferencias < 0,04 en el partido completo son ruido.

2.3 Qué cuenta como posesión

Según CHALLENGE.md, la posesión cambia cuando el rival gana el balón **controlado**. No cuentan un toque sin control, un desvío que no intercepta ni un duelo aéreo sin control posterior. La GT sale del tracking corregido de Metrica de forma mecánica, y la referencia práctica son los 5 minutos públicos (17 posesiones, 14,2 s de media, 17,6 % de posesiones de menos de 3 s). Esto fue decisivo (sección 4.3).

2.4 Las reglas que más nos condicionan

- **Ningún LLM en la nube puede ver los datos del reto ni extractos de ellos** (T&C). Nuestro agente es un LLM en la nube, así que nunca lee los datos: escribe el código, el código se ejecuta en local y solo vuelven números agregados (ADR-0004, sección 11).
- Prohibido etiquetar a mano el resultado; prohibido usar otras fuentes de posesión de este partido.
- El fichero tiene que regenerarse **idéntico** desde el repositorio.
- **No hay leaderboard**: los 5 minutos públicos no sirven para elegir modelos (el propio repo oficial lo demuestra: con ellos se elige mal hasta el suavizado del baseline).

3. Los datos y qué hacemos con cada uno

Fuente	Qué es	Uso actual y por qué
ATD táctico	Posición de los jugadores y del balón en cada frame, automático, sin identidades (46 slots que se fragmentan)	**La base de todo.** Problemas: falta el balón en el 41 % de los frames puntuados (en ~134 huecos largos) y la trayectoria del balón está muy filtrada (casi no se ven los toques).
Vídeo táctico	1080p, homografía válida en todos los frames; audio mudo	Probamos un detector de balón (YOLO): **descartado**, solo acierta el 24 % (E025).
Broadcast	Cámara de tele con su propio tracking; no sincronizada; audio real con comentarista en inglés	Alineado con el táctico (un desfase fijo por parte, E026). Como fuente de balón **no sirve** (rellena el 7,5 % de los huecos, E023). El silbato no se detecta (E029); el comentario se transcribe bien pero aporta poco (E033).
Smart Tagging	Eventos automáticos de Metrica (fases, balones parados)	**Descartado**: +0,008, dentro del ruido, y solo el 13 % de los huecos largos acaba en un balón parado etiquetado (ADR-0007).
GT pública 5 min	Las etiquetas reales de los primeros 5 minutos	Solo prueba de humo (detectar roturas) y para conocer la forma de la definición de posesión. **Nunca elige modelos.**
Metrica sample-data	3 partidos públicos con tracking limpio y eventos	Banco de validación y entrenamiento. Su GT sale de los eventos.
DFL / Sportec	7 partidos de la Bundesliga con tracking corregido y flags de posesión por frame	Añadidos el 22-23 oct (banco v3). Su GT sale del tracking, como la del reto.

Lo más importante de los datos: el balón falta justo en los momentos que deciden la posesión (choques, áreas llenas, balones aéreos). Por eso el reto no se gana mirando solo al balón, sino a lo que hacen los 22 jugadores, que es lo que hemos atacado esta semana.

4. Cómo validamos sin leaderboard

4.1 El banco

Como no hay leaderboard y la GT completa es privada, construimos un **banco de validación** con partidos públicos. Su tracking limpio se **estropea a propósito** para parecerse al del reto: se borra el balón en huecos largos (más probables con balón muerto), se suaviza su trayectoria como lo hace el tracker de Metrica, se parten las trayectorias de los jugadores en 46 slots sin identidad y se añade ruido. (ADR-0005, ADR-0006, ADR-0009.)

4.2 Cómo sabemos que el banco se parece al reto

Con dos anclas: (1) el baseline oficial tiene que dar en el banco el mismo orden y casi la misma escala que los cuatro números que publicó la organización para el partido real; (2) estadísticas agregadas del

ATD real (porcentaje de balón ausente, longitud de los huecos, dinámica del balón).

Baseline oficial	raw	s25	s50	s125
Reto real (publicado)	0,049	0,200	0,243	0,224
Banco Metrica (GT controlada)	0,040	0,194	0,280	0,275
Banco DFL (mismo simulador, sin tocar)	0,025	0,203	0,265	0,236

Los dos bancos reproducen el orden del reto (s50 > s125 > s25 > raw) y quedan ~0,02-0,04 más fáciles. Por eso los números del banco sirven para **ordenar** modelos, no para predecir la nota exacta.

4.3 La corrección clave: la posesión «controlada» (ADR-0012)

El 22 de octubre descubrimos que el banco medía otra definición: la GT de Metrica cambiaba de equipo en **cada** recuperación, aunque durase un segundo (36 % de posesiones de menos de 3 s, frente al 17,6 % de la GT pública). Aplicamos la regla «un robo solo cuenta si el nuevo equipo conserva el balón al menos T segundos» (tras un parón siempre cuenta). T se elige por la **forma** de la distribución, nunca por la nota: con T = 1,5 s Metrica reproduce la GT pública (17,5 % y 13,7 s). En DFL hace falta T = 2 s (17,5 %).

Por qué importa: el mismo modelo, sin tocarlo, pasó de 0,542 a 0,628. Reentrenarlo con la nueva definición no aportó (E021): el modelo ya era bueno; lo que estaba mal era el examen. Desde entonces todo se mide con la GT controlada y los números anteriores no son comparables.

4.4 El protocolo para aceptar cambios (ADR-0008)

- Siempre **dejando un partido fuera**: se entrena con los demás y se puntúa el que no se ha visto, en todas las combinaciones. Los parámetros del Viterbi también se eligen sin mirar el partido retenido.
- Un cambio entra solo si sube la nota agregada **≥ 0,01** y mejora en **al menos 7 de 10** partidos (antes, 3 de 3). Así evitamos quedarnos con la variante que tuvo suerte.
- Antes de aceptar features nuevas se comprueba que su distribución en el ATD real se parece a la del banco (`feature_shift`), porque una vez unas features de toques funcionaban en el banco y no en el reto (E012-E013).
- Todo se registra en `docs/experimentos.md`, también lo que falla.

4.5 El banco v3: de 3 a 10 partidos

Con 3 partidos, una mejora pequeña no superaba el ruido. El 22-23 oct añadimos los 7 partidos de DFL (descargados abriendo las URLs de figshare en el navegador, que bloquea las descargas automáticas). Su GT sale de los flags de posesión de su tracking, la misma naturaleza que la del reto, aunque también cambia de equipo con cada toque (43,7 % de posesiones de menos de 3 s), así que necesita la regla controlada. La referencia en el banco v3 es **0,6470** (E030). Detalle útil: entrenar con 9 partidos en vez de 2 ya sube los de Metrica unos 0,04, así que el modelo final se entrenará con los 10.

5. El modelo, paso a paso

Es un sistema de tres piezas. La idea: un clasificador da probabilidades por frame y un decodificador las convierte en posesiones coherentes.

1. **Features por frame.** Unos 65 números en el modelo actual (más de 150 con las familias nuevas). Todo es colectivo y sin identidades: cercanía de cada equipo al balón, toques (con un umbral relativo a cada partido, porque el balón real va filtrado), receptor probable, velocidad colectiva, forma de los equipos, contexto de los huecos sin balón... Se calculan también en ventanas antes y después de cada frame (el sistema es offline: ve el partido entero).
2. **Capa 1: LightGBM** (127 hojas, 400 rondas) que da P(H), P(A), P(D). Se entrena también con los equipos intercambiados para no tener sesgo de local, y la predicción se simetriza.
3. **Capa 2 (apilado, ADR-0011)**: otro LightGBM que ve las probabilidades de la capa 1 resumidas en ventanas de 1 a 10 s hacia atrás, centradas y hacia delante. Se entrena con probabilidades fuera de muestra para no aprender de predicciones demasiado buenas. Elimina saltos sueltos y aporta contexto largo.
4. **Viterbi**: busca la secuencia H/A/D más probable de cada parte, cobrando por cada cambio. Como decide la parte entera de una vez, coloca cada frontera donde mejor encaja la evidencia a los dos lados: no hay retraso. Es imprescindible: sin Viterbi, el mismo modelo saca 0,21; con él, 0,65-0,72.

Reproducibilidad. El modelo entrenado se guarda en el repositorio (no se reentrena al entregar). El entrenamiento es determinista bit a bit (lo arreglamos el 22 oct: LightGBM elegía el método de histograma cronometrando la máquina, E024). `make_submission` genera el CSV, lo valida con el validador oficial e imprime su sha256; dos ejecuciones dan el mismo fichero.

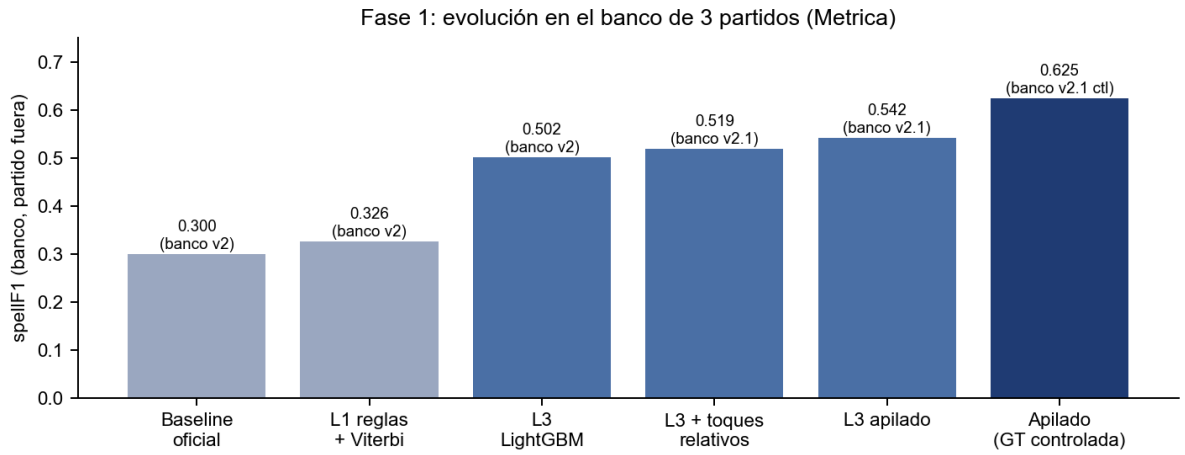


Figura 2. Evolución en el banco antiguo de 3 partidos. Ojo: los bancos cambian (v2, v2.1, GT controlada), así que las barras de grupos distintos no se comparan entre sí; cada mejora se midió frente a la anterior en el mismo banco.

6. Lo que hemos probado, con números

Cada fila resume un experimento. «Entra» significa que pasó el protocolo y forma parte del modelo.

Exp.	Qué	Resultado	Decisión y por qué
E001-E002	Banco Metrica + simulador calibrado con el baseline	Reproduce el orden del reto	Base de toda la validación
E003-E004	L1: reglas + Viterbi (+ Smart Tagging)	0,337-0,363	Superado por L3
E005-E006	Diagnóstico del ATD real (agregados)	41 % sin balón, huecos largos	Banco v2 con huecos largos
E007-E010	L3: LightGBM + Viterbi; más capacidad	0,502 (v2)	**Entra** (ADR-0007)
E012-E014	Features de toques: umbral fijo → relativo	Fijo: espejismo; relativo +0,054	**Entra el relativo**: el balón real va filtrado (ADR-0009)

Exp.	Qué	Resultado	Decisión y por qué
E015-E017	Empuje de bloque; aleatorización del dominio	+0,009; neutro	Descartados
E018-E019	Apilado (capa 2)	0,542 (+0,029, 3/3)	**Entra** (ADR-0011)
E020-E021	Análisis de fallos; GT controlada	0,542 → 0,628 (misma predicción)	Se evalúa con GT controlada (ADR-0012)
E022-E024	Artefacto final; determinismo	CSV reproducible, sha 252716b0…	**Entregable actual**
E023	Broadcast como fuente de balón	7,5 % de huecos rellenables	Descartado
E025	Detector YOLO en el vídeo	24 % a < 2 m del balón	Descartado
E026	¿Desfase del broadcast constante?	Sí, 99 % de los frames	El audio es utilizable
E027	DFL al banco (GT del tracking)	Necesita T = 2 s; calibrado sin tocar	Banco v3
E028	Acierto por longitud de pase	Pases perdidos: 0,58 tras la pérdida	Confirma el fallo nº 1
E029	Silbato en el audio	Sin señal	Descartado
E030	Referencia en el banco v3	**0,6470**	Nueva vara de medir
E033	Comentario en inglés (Whisper local)	Parones fiables, pero ya los detectamos	Fuera del modelo; sirve de comprobación
E034	Modelo profundo (atención + BiGRU) promediado	0,6570 sobre la referencia	Pasaba…
E035	**Familias de features**	**0,7185** (+0,072, 9/10)	**Candidato a entrar** (pendiente ablación)
E036	Coste de cambio dinámico (idea PathCRF)	Sin ganancia	Descartado
E037	Modelo profundo sobre las familias	0,7172 / 0,7134	Descartado: ya no aporta

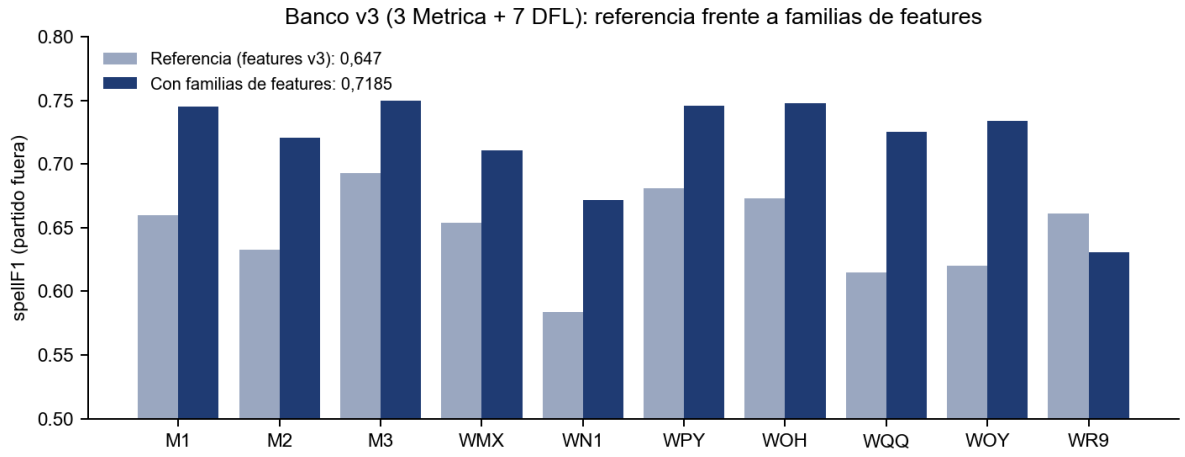


Figura 3. Banco v3, partido por partido. Las familias mejoran 9 de 10 partidos; el único que baja es J03WR9 (0,661 → 0,631), que estudiaremos.

7. Dónde fallamos y por qué

El análisis de fallos (E020, `docs/investigacion/02_analisis_fallos.md`) clasifica cada posesión real que no encontramos. Está medido sobre el modelo anterior, en el banco con GT controlada; las familias nuevas atacan precisamente estos fallos, y repetiremos el análisis con el modelo nuevo.

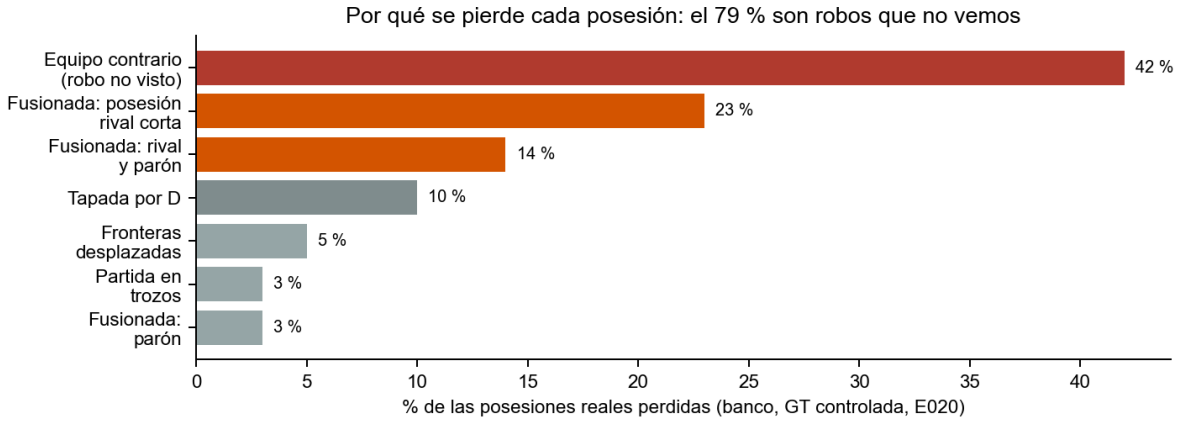


Figura 4. Causas de las posesiones perdidas. «Equipo contrario» y «fusionada» son dos caras del mismo fallo: no ver un cambio de posesión.

7.1 Robos en juego que no vemos (79 % de las pérdidas)

- Solo la mitad de los cambios H↔A tenían una frontera nuestra a menos de 2 s. Cuando la detectamos, la colocamos bien (desfase mediano de 0-1 frame): el problema no es llegar tarde, es no verlo.
- Las intercepciones se encontraban el 53 % de las veces; los balones sueltos, el 58 %; tras un pase perdido acertábamos el 58 % de los frames (E028). En cambio, los cambios de juego y balones largos que alguien controla se aciertan al 93-95 %.
- **Por qué**: el modelo miraba sobre todo la cercanía al balón y los toques, pero en el ATD los toques casi no se ven y el balón se pierde justo en el choque. Incluso con el balón perfecto, el jugador más cercano es del equipo poseedor solo el 79 % de las veces.

7.2 Huecos largos sin balón (38 % de los frames)

- Acierto por frame: 0,78 en huecos largos frente a 0,92 con balón. El juego vivo se confundía con balón muerto el 22 % de las veces, y cada D falso parte una posesión.
- Rellenar el balón con otras fuentes no funcionó (broadcast 7,5 %, YOLO 24 %): el balón falta en las mismas jugadas para todos. Hay que inferir sin balón, con la colocación y el movimiento de los jugadores.

7.3 Duelos, aéreos y despejes

Cerca de un duelo acertábamos el 70 % de los frames; las posesiones que acaban en despeje solo se encontraban el 12,5 %. En 2D no hay altura del balón, y en un despeje la posesión sigue siendo de quien despeja hasta que el rival controla, pero el modelo cambiaba antes por cercanía.

7.4 Infrasegmentación

Predecíamos menos posesiones de las que hay (2.298 frente a 2.885 en el banco v3). Es consecuencia del fallo 7.1: cada robo no visto funde posesiones. Con las familias nuevas pasamos a 2.669.

7.5 Lo que no es problema

El retraso de las fronteras (0-1 frame), los huecos cortos y partir posesiones largas. No merece la pena invertir ahí.

8. La mejora de esta semana: features como las mira un entrenador

Tras investigar trabajos previos (sección 10) y pensar el problema como un entrenador, reorganizamos las features en **familias** (en lugar de versiones v5, v6, v7...). Todo sale de las posiciones, sin identidades, así que funciona también cuando falta el balón. Cada señal incluye su **cambio entre el segundo anterior y el posterior**, porque un robo se ve en el cambio de comportamiento, no en el nivel.

Familia	Idea de entrenador	Cómo se mide
Balón	Hacia dónde avanza; si va en vuelo largo; si está quieto	Velocidad del balón proyectada hacia cada portería, antes y después; balón rápido y lejos de todos (la posesión se mantiene durante el vuelo); tiempo que lleva quieto
Jugadores	Quién aprieta, quién esprinta, quién se desmarca, qué hace el portero	Jugadores a < 15 m que se acercan al balón a > 3 m/s; nº de sprints (contraataque o contrapresión); ritmo al que los atacantes se separan de su marcador; el más retrasado como portero (solo si está a < 25 m de su portería) y si vuelve a su línea
Bloques	Cómo de juntos y abiertos están; si la defensa adelanta o recula; achicar y apretar	Longitud, anchura, superficie (envolvente convexa), dispersión (stretch index), altura de la línea defensiva y de la delantera, distancia entre líneas y cuánto va adelantado un bloque respecto al otro. Los niveles, relativos al propio partido
Estructura	Forma con y sin balón; quién va adelantado; cambios de formación	Jugadores por detrás del balón (el que defiende tiene más); jugadores en campo rival; a qué se parece la forma actual del equipo: a su forma abierta (con balón) o a la cerrada, aprendidas sin etiquetas en el propio partido; cuánto cambia la forma en 3 s
Reanudación	Un balón parado tiene una colocación típica	Jugadores quietos, área llena (córner, falta), alguien pegado a la banda (saque de banda), alguien en el área pequeña (saque de puerta), grupo compacto (barrera), formación de saque de centro

Resultado (E035): 0,7185 frente a 0,6470 (+0,072), mejora en 9 de 10 partidos y las posesiones predichas suben de 2.298 a 2.669 (reales 2.885). Es la mayor mejora desde el apilado.

Comprobación de dominio

Antes de evaluar, comparamos la distribución de cada feature nueva en el ATD real y en el banco. Las medidas de bloque salían desplazadas (en el ATD real los equipos aparecen ~5 m más cortos: puede ser estilo o jugadores no detectados), así que las expresamos **relativas al propio partido**, igual que hicimos con los toques. Los cambios antes/después cuadraban desde el principio.

Cautelas antes de entregarlo. (1) Las features del portero están entre las más importantes y en el ATD real su distribución difiere algo (desajuste 0,22): la ablación dirá si dependemos de ellas. (2) Hay que descartar que el modelo aproveche artefactos del simulador (por ejemplo, el balón que el simulador interpola en los parones). (3) J03WR9 empeora. (4) Falta la prueba de humo en el reto.

9. Lo que probamos y descartamos (y por qué)

Descartar también es avanzar: cada una de estas vías parecía prometedora y la medimos antes de invertir más tiempo.

Idea	Por qué parecía buena	Qué pasó	Conclusión
Smart Tagging	Marca balones parados y el equipo de cada fase	+0,008 (ruido)	No compensa depender de él
Rellenar el balón con el broadcast	Otra cámara podría ver el balón cuando la táctica no	Solo el 7,5 % de los huecos	Pierde el balón en las mismas jugadas

Idea	Por qué parecía buena	Qué pasó	Conclusión
Detector de balón en el vídeo (YOLO COCO)	El vídeo táctico es 1080p con homografía	Incluso donde el ATD ve el balón, solo el 24 % a < 2 m	Balón demasiado pequeño para un detector genérico. Queda abierta una versión reentrenada con el propio ATD
Silbato del árbitro	Marcaría el inicio de los parones al instante	Sin señal en el audio	La grada y el comentario lo tapan
Comentario en inglés	Confirmar situaciones y posesiones	Los parones que comenta ya los detectamos (techo ~+0,005); el nombre del jugador apenas indica el equipo (0,71 frente a 0,57)	Comprobación independiente, no entra en el modelo
Coste de cambio dinámico (PathCRF)	Abaratar cambiar donde hay señales de robo	La selección nunca lo elige	La capa 2 ya ve esas señales
Modelo profundo (atención + BiGRU)	Lo social es lo que más aporta en PathCRF; infiere el balón	Sobre la referencia, +0,010; sobre las familias, nada o peor	Fuera: complica sin aportar
Entrenar con la GT controlada	Optimizar la definición correcta	−0,002	Basta con evaluar con ella

10. No reinventamos la rueda: trabajos que hemos usado

Trabajo	Qué aporta	Cómo lo usamos
PathCRF (Kim et al., 2026)	Posesión sin balón con atención entre jugadores y CRF; 92 % de acierto de equipo por frame en los mismos 7 partidos DFL	Inspiró el modelo profundo y el coste dinámico (ambos medidos y descartados al final) y la idea de que lo colectivo es lo que más aporta
Ball Radar / TranSPORTmer	Inferir la posición del balón a partir de los jugadores	Tarea auxiliar del modelo profundo
Pressing Intensity (Bekkers, 2025)	Presión como probabilidad de interceptar	Familia jugadores: quién aprieta
Contrapresión (Bauer y Anzer, 2021)	Detectar la contrapresión tras pérdida con tracking	Sprints y presión tras el robo
Compacidad por fase (AMISCO, LJMU)	Con balón los equipos son más anchos, largos y extensos	Familia bloques
Formaciones (Bialkowski, Shaw y Glickman, SoccerCPD)	Forma distinta con y sin balón; cambios de formación	Familia estructura
SoccerNet-Echoes	Whisper sobre comentarios; falla con los nombres	Lista de nombres de las plantillas como pista

11. Decisiones tomadas (ADR) y por qué

Todas están en `docs/decisiones/`, en estado **Propuesta**: falta que las reviséis y las marquéis como aceptadas.

ADR	Decisión	Motivo
0001	GitHub, ramas y PR con revisión; documentación en el repo	Los agentes leen el repo, no el chat; dos personas conocen cada cambio
0002	Los datos del reto nunca van a git	Licencia y tamaño
0003	Python 3.11 + uv + LightGBM	Ecosistema de fútbol en Python; entornos reproducibles

ADR	Decisión	Motivo
0004	Los agentes no ven los datos del reto	T&C: prohibido enseñar datos o extractos a un LLM en la nube. **Práctica desde el 22 oct (pendiente de que la aprobéis)**: el agente ejecuta scripts de solo agregados con `scripts/run_aggregate.sh`, que solo muestra la salida si acaba bien; si falla, el log lo lee una persona
0005-0006	Validar con un banco externo calibrado con el baseline	No hay leaderboard
0007	L3 como entrega principal; modelo versionado	+0,18 sobre el baseline; reproducibilidad
0008	Protocolo de aceptación (≥ 0,01 y mayoría de partidos)	Evitar quedarnos con la suerte
0009	Balón filtrado en el banco y toques relativos	El balón real está filtrado
0010	Fusión del balón (broadcast + vídeo)	Probado: no pasa la puerta
0011	Modelo final: L3 apilado	+0,029 en 3/3
0012	Evaluar con la posesión controlada	La GT del banco medía otra definición
0013	Audio del broadcast	Hay audio; silbato sin señal; comentario solo como comprobación

Cumplimiento de las reglas

- Ningún dato del reto ha pasado por el agente: solo nombres de fichero, tamaños y números agregados (porcentajes, percentiles, notas). La transcripción del comentario y los logs de error se quedan en `data/derived/`, que el agente no lee.
- Los datos no están en git; los derivados (alineación, transcripción) tampoco.
- Ninguna etiqueta se ha puesto a mano; la GT privada no se usa; la GT pública solo para humo y para la forma de la definición de posesión.

12. Qué estamos haciendo ahora y qué viene

Paso	Qué	Estado
1	Ablación: quitar cada familia (empezando por «jugadores», que incluye al portero) para saber de dónde sale la mejora	La primera se cortó al reiniciarse la sesión; se relanza
2	Entender por qué empeora J03WR9 y repetir el análisis de fallos con el modelo nuevo	Pendiente
3	Artefacto final con los 10 partidos y regenerar `La MasIA.csv` (dos veces, mismo sha) + humo con los 5 minutos públicos	Pendiente; el código ya lo soporta
4	Mejoras baratas: ensamblado de semillas, calibración, reelegir el Viterbi en el banco v3	7-9 nov
5	Congelar el 14 nov: clon limpio que regenere el mismo sha; documento técnico definitivo	10-14 nov
6	Repo público, PR a main aprobada, PDF, subir el formulario	15-16 nov

Qué necesitamos de cada uno

- **Manel**: enviar el email a la organización (Q2 agregados y LLM; Q4 versionar derivados; Q5 GT pública para entrenar; Q6 audio). Invitar a los compañeros en GitHub.
- **Compañeros**: aceptar la invitación, clonar, leer este informe y `docs/01_contexto_completo.md`, revisar y aprobar la PR `banco-v3 → main` y los ADR (sobre todo el 0004).

- **Los tres**: confirmar la inscripción como «La MasIA» antes del 10 nov; uno de nosotros sube el formulario con su cuenta Google (CSV y PDF con el nombre del equipo).

13. Cómo empezar y dónde está cada cosa

Instalación (abrir Claude Code **desde la carpeta del repo**, para que se aplique el bloqueo de `data/`):

```
git clone --recursive https://github.com/ManelCM/FCBCN_HACK_2027.git C:/dev/hack_barca
cd C:/dev/hack_barca && git checkout banco-v3 && uv sync
```

Datos del reto: del Drive de la organización a `data/` y la variable `MTAH_DATA_DIR`. Metrica se descarga solo; DFL, abriendo las URLs en el navegador y luego `uv run python -m hackbarca.io.dfl --from-downloads <Descargas>`.

Qué	Dónde
Contexto desde cero	docs/01_contexto_completo.md
Plan de investigación y estado del arte	docs/04_plan_investigacion.md
Todos los experimentos con números	docs/experimentos.md
Decisiones	docs/decisiones/ (ADR 0001-0013)
Diario del equipo	docs/LOG.md
Análisis de fallos explicado	docs/investigacion/02_analisis_fallos.md
Features (familias)	src/hackbarca/features/frame_features.py y tactical.py
Modelo y decodificación	src/hackbarca/models/l3.py, decode/viterbi.py
Evaluar en el banco	uv run python -m hackbarca.pipeline.tune_l3 --bench v3 --features touch+ball+players+blocks+structure+restart --stack --controlled 1.5 --controlled-dfl 2 --train-gt raw
Generar la entrega (datos reales)	scripts/run_aggregate.sh make_submission uv run python -m hackbarca.pipeline.make_submission --model l3 --team-name "La MasIA"

14. Glosario

Término	Significado
spellF1	Métrica oficial: F1 de posesiones enteras emparejadas por solape (IoU 0,3-0,7)
macroF1	F1 media por frame de H, A y D; desempate
ATD	Automatic Tracking Data: el tracking automático del reto
GT	Ground truth, la verdad con la que se puntúa
GT controlada	Verdad del banco en la que un robo solo cuenta si dura ≥ T segundos
Banco	Partidos públicos estropeados para parecerse al ATD; nuestro juez
Partido fuera (LOGO)	Entrenar con todos menos uno y puntuar ese
Viterbi	Algoritmo que elige la secuencia de estados más probable cobrando por cada cambio
Apilado	Un segundo modelo que aprende de las probabilidades del primero
Ablación	Quitar una pieza para medir cuánto aporta
Oráculo	Sustituir la predicción por la verdad en ciertos frames para medir el techo de mejora
Infrasegmentación	Predecir menos posesiones de las que hay